

深度学习发展综述

谭笑枫 李广帅

(火箭军工程大学, 陕西西安 710025)

摘 要 深度学习是基于数据表示的一类更广的机器学习方法, 它的出现不仅推动了机器学习的发展, 而且促进了人工智能的革新。深度学习的研究成果已经被成功应用在语音识别、图像分类识别、地球物理等领域, 具有巨大的发展潜力和社会价值。文中在对深度学习研究历史简述的基础上, 重点介绍了卷积神经网络、深度置信网络、自编码器和循环和递归神经网络的经典算法及其应用, 最后对深度学习的发展趋势提出展望。

关键词 深度学习 卷积神经网络 深度置信网络 自编码器 循环和递归神经网络

Review of deep learning development

TAN Xiao-Feng LI Guang-Shuai

(Rocket Force University of Engineering, Xi'an, Shaanxi, China, 710025)

Abstract Deep learning is a broader machine learning method based on data representation. Its emergence not only promotes the development of machine learning, but also the innovation of artificial intelligence. The research results of deep learning have been successfully applied in the fields of speech recognition, image classification and recognition, geophysics, etc., which has great development potential and social value. Based on the brief history of deep learning, this paper mainly introduces the classic algorithms and applications of convolutional neural network, deep belief network, autoencoder and recurrent and recursive neural network, and finally puts forward the prospect of the development trend of deep learning.

Key Words Deep learning Convolutional neural network Deep belief network Autoencoder Recurrent and recursive neural network

1 引 言

深度学习 (Deep Learning) 是人工智能机器学习的一种。它的出现主要为解决那些对于人来说很容易执行, 但很难形式化描述的任务。对于这些任务, 我们可以凭借直觉轻易解决, 但对于人工智能来说却很难解决。针对这些比较直观的问题, 深度学习这种方案可以让计算机从经验中进行学习, 并根据层次化的概念体系来理解世界。让计算机从经验中获取知识, 可以避免由人类来给计算机形式化地制定它需要的所有知识, 而层次化的概念让计算机利用较简单的概念来学习复杂的概念。通过多层的“学习”, 计算机能够用简单形象的表示来表达复杂抽象的表示, 解决了表示学习的核心问题^[1]。如今, 深度学习的研究成果已成功应用于语音识别、模式识别、目标识别、自然语言编程、人机对弈、人工智能、智慧城市等领域。本文在对深度学习研究历史简述的基础上, 重点介绍了卷积神经网络、深度置信网络、自编码器和循环和递归神经网络的经典算法及其应用, 最后对深度学习的发展趋势提出展望。

2 深度学习的历史沿革

2006 年, Hinton^[2]教授在《科学》上发表论文, 提出深层网络训练中梯度消失问题的解决方案, 人类对于人工神经网络的研究开始进入深度学习的时代。2011 年, ReLU^[3]激活函数的提出, 有效地抑制梯度的消失。2012 年, 深度神经网络 (Deep Neural Network, DNN) 技术在图像识别领域取得惊人的效果, 2012 年 Hinton 教授的团队利用卷积神经网络 (Convolutional Neural Network, CNN) 设计了 AlexNet^[4], 使之在 ImageNet 图像识别大赛上打败了所有运用传统方法的团队, 使得卷积神经网络成为计算机视觉领域中最重要工具之一。2016 年末至 2017 年初, 基于深度学习设计的 “AlphaGo^[5]” 在中国棋类网站上以 “大师” (Master) 为注册账号与中、日、韩数十位围棋高手进行快棋对决, 连续 60 局无一败绩。

从 Hinton 教授提出深度学习这一概念开始发展到现在, 深度学习已产生了一系列的学习算法, 经典的有卷积神经网络、深度置信网络、自编码器、循环和递归神经网络等, 下面依次对这些经典算法进行介绍。

3 深度学习的经典算法及应用

3.1 深度卷积神经网络

卷积神经网络 (Convolutional Neural Networks, CNN) 是一种特殊的前馈神经网络, 为了避免层级之间全连接造成的参数冗余, 它在结构设计上选用了局部连接, 这种连接方式符合生物神经元的稀疏响应特性, 大大降低网络模型的参数规模, 对训练数据量的依赖性也大大降低。在 CNN 出现之前, 人工智能领域在反向传播算法 (Back-Propagation, BP) 的研究中取得了突破性进展, 第一个被提出的卷积神经网络——时间延迟网络 (Time Delay Neural Network, TDNN)^[6]就是在 BP 框架内进行学习。因此卷积神经网络的结构和反向传播网络 (Back-Propagation Network) 结构存在类似性, 都是由一层层的结构组成, 但功能不尽相同。卷积神经网络的结构主要可以分为输入层、卷积层 (Convolution Layer)、池化层 (Pooling layer)、全连接层和输出层。这种结构使得 CNN 非常适合处理二维结构数据, 相比其他 DNN 在图像处理领域上具有天然优势。

深度卷积神经网络, 从提出发展到现在, 出现了许多典型的网络模型, 在许多领域上都得到了较好的应用。

3.1.1 LeNet5

LeNet5 是由 Lecun Y.^[7]等在 1998 年提出卷积神经网络, 是为了解决手写字符识别的问题。LeNet5 共有 5 个隐藏层, 分别为 3 个卷积层和 2 个池化层。这个网络虽然很小, 但是它包含了深度学习的基本模块, 即卷积层、池化层和全链接层, 是其他深度学习模型的基础。作为一个非常成功的深度卷积神经网络模型, 目前多应用于银行系统中识别支票上的数字等场景。

3.1.2 AlexNet

2012 年, Krizhevsky 等^[4]提出了一个深度卷积神经网络 AlexNet, 为解决大量数据集基础上的物体识别任务提供了方法。该网络在 ILSVRC-2012 大赛中凭借 15.4% 的 top-5 错误率, 以领先第二名 10.8 个百分点的优势获得冠军, 真正展示了深度卷积神经网络的优势。此后, 深度卷积神经网络成为人们在图像分类中使用的重要方法。

AlexNet 模型的优势在于: 采用 ReLU 激活函数、Dropout、数据扩张来减少过拟合和参数之间相互依赖性问题; 采用最大池化操作提升特征丰富性; 利用局部响应归一化层提升模型的泛化能力。同时, 还可以利用多 GPU 进行加速。

3.1.3 VGG 和 GoogLeNet

VGG 是 Simonyan K. 等^[8]提出了一种深度卷积网络模型, 用于大规模图像分类并取得了较好的效果。而 GoogLeNet 是 Szegedy C. 等^[9]提出了一种全新的深度学习结构。VGG 和 GoogLeNet 是 ILSVRC-2014 大赛中的双雄, GoogLeNet 获得了第一名, VGG 获得了第二名。这两类模型结构的共同特点是层次比 AlexNet 更深。不同之处在于, VGG 继承了 LeNet 以及 AlexNet 的一些框架结构, 而 GoogLeNet 则做了更加大胆的网络结构尝试, 虽然深度只有 22 层, 但大小却比 AlexNet 和 VGG 小很多, 并且 GoogLeNet 的参数相比 VGG 和 AlexNet 大大减少, 节约了计算机内存资源, 性能更具有优越性。

3.1.4 深度卷积神经网络的应用

深度卷积神经网络由于其结构特征, 特别适合处理二维结构数据, 因此在处理图像领域上的问题具有天然优势。尤其在目标检测和识别领域, 以深度卷积神经网络为基础提出了基于区域建议的目标检测与识别算法——R-CNN^[10]。该算法可以使深度学习的方法得到更具表达力的特征, 取代人为设计特征以提高识别精度, 同时采用区域建议的方式代替滑窗方式, 减少计算量, 并且还通过加入边界框回归的策略进一步提高识别精度。为提高效率, 在 R-CNN 之后又提出了 Fast R-CNN^[11]和 Faster R-CNN^[12]算法, 进一步提高了检测速度, 并实现了端到端的处理任务。

除此之外, 其他的算法也在不同领域得到了应用。LeNet5、BP 网络常用于解决手写字符识别问题; AlexNet、VGG、GoogLeNet 等在历年的 ImageNet 图像识别大赛中取得了优异的成绩; R-CNN、Fast R-CNN 和 Faster R-CNN 在目标检测和识别方面取得较大的成果; 同时 CNN 也被用于 SAR 影像的变化检测^[13]。

深度卷积神经网络在地球物理方面中也得到了应用, 例如卷积神经网络能有效去除随机噪声, 且与常规去噪算法相比具有更强的去噪能力^[14], 定位电磁场数据的地下目标^[15]和高层大气和电离层活动的预测^[16]等。

3.2 深度置信网络

深度置信网络 (Deep Belief Network, DBN) 是由 Hinton 等^[17]提出为解决快速、自动学习特征问题的一种快速学习算法。它打开了深度学习模型扩展的大门, 并将其应用于实际生活的各个领域。它由两部分组成, 第一部分为多层无监督的受限玻尔兹曼机 (Restricted Boltzmann Machine, RBM), 作用是预训练网络; 第二部分为一层有监督的前馈反向传播 (BP) 网络, 作用是使 RBM 堆叠的网络更加精细化, 提升模型分类性能。

DBN 训练过程可以分为两个阶段, 即无监督训练阶段和微调阶段。第一阶段采用无监

督的贪婪逐层训练法,以获得每层的条件概率分布;第二阶段采用包括利用带标签数据和BP算法对网络参数进行微调,从而达到训练效果。

DBN结合了无监督学习和有监督学习各自的优点,克服了BP网络因随机初始化权值参数而容易陷入局部最优和训练时间长的缺点,并具有高灵活性,容易拓展,不仅在图像处理、语音识别领域网络预训练中应用广泛,还是构建新型深度学习网络的结构基础。尽管如此,DBN还面临以下两个方面的挑战:一是当图像维度很高时,算法要能够合理地建模,且计算简便;二是对象常常分布在图像的局部,要求特征表示对输入局部变换具有不变性。以上两个原因使得DBN很难全尺寸衡量高维图像。

3.2.1 卷积深度置信网络

为解决DBN面临的挑战,科学家们又提出了卷积深度置信网络(Convolutional Deep Belief Networks, CDBNs)。Desjardins G.等^[18]证明了DBN适应卷积方式运作,表明卷积深度置信网络可以利用邻域像素的空域关系,进行卷积操作,达到生成模型的变换不变性,而且容易得到变换后的高维图像。

与DBN相比,CDBNs具有以下不同:一是可以对高维图像做全尺寸衡量;二是特征表示对输入局部变换具有不变形;三是该方法加入了最大池化,降低了图像的维度,减少了计算量。

3.2.2 栈式自编码器

栈式自编码器(Stacked Auto-Encoder, SAE)与DBNs具有相关性。它是用栈式自编码器来替换传统DBNs里面的RBMs。这就使得SAE可以通过同样的规则来训练产生深度多层神经网络架构,但它缺少层的参数化的严格要求。这样这个结构就很难将采样输入采样空间,这就使得网络更难捕捉它的内部表达。但是,降噪自编码器(Denoising Automatic Encoder, DAE)却能很好地避免这个问题,并且比传统的DBNs更优。它通过在训练过程添加随机的污染并堆叠产生场泛化性能。

3.2.3 深度置信网络的应用

DBN在许多领域都有广泛应用。在文字检测领域可以实现手写数字的分类和识别等功能^[19-21],在人脸及表情识别领域具有人脸表情识别和多姿态人脸识别等功能^[22-24],在遥感图像领域内可以实现高光谱检测、遥感图像多类别物种分类和SAR遥感图像三级变化分析等功能^[25-27]。

3.3 自编码器

自编码器(Auto-Encoder, AE)是一种能够通过无监督学习,学到输入数据高效表示的人工神经网络,是Rumelhart D.^[28]等于1986年提出的。自编码器含有三层结构,即输入层、隐藏层和输出层。隐藏层可以产生编码表示输入,维度一般远小于输入数据,使得自编码器可用于降维。同时自编码器可作为特征检测器,应用于深度神经网络的预训练中。

自编码器通过简单地学习将输入复制到输出工作,即通过加强一些约束,强制模型考虑输入数据的哪些部分需要被优先复制,从而达到学习数据的有用特性。目前,基于自编码算法也产生了许多改进算法。

3.3.1 栈式自编码器

栈式自编码器(Stacked Auto-Encoder, SAE)是由Bengio Y.^[29]等于2007年提出的。

它由多层自编码器构成的一种神经网络模型。栈式自编码器的基本单元是自编码器。自编码器是浅层神经网络，它的目的是让输入和输出保持一致。栈式自编码器把多层自编码器堆在一起进行逐层学习，将相邻的层级视为一个简单的只有两层的浅神经网络，利用浅层学习算法可以达到很好的训练效果，然后再将逐层学习后的层级“迭”在一起形成深度神经网络。

栈式自编码器的训练过程为：首先采用逐层贪婪训练法依次训练深度神经网络中的每一层，即用原始输入训练第一层网络参数，再将该隐藏层的输出作为下一层的输入，按此方法反复执行，从而达到依次逐层训练学习各层网络的参数的目的。在进行无监督预训练后，设计一个分类器添加在自编码器的编码层上，然后使用分类器利用第一步学习到的初始化参数对模型进行微调。

栈式自编码器利用自编码器这种浅层神经网络避免深度网络所面临的梯度爆炸和衰减问题，并采用“堆栈”的形式来加快学习速率，提高网络的泛化能力。同时，栈式自编码器采用无监督的算法和有监督微调的方法，避免部分深度神经网络容易获得局部最优和收敛慢的特点，与深度置信网络类似。

3.3.2 稀疏自编码器

稀疏自编码器 (Sparse Auto-Encoder, SAE) 是一种无监督机器学习算法。它是在传统自编码器的基础上通过增加一些稀疏性约束得到的。这个稀疏性是针对自编码器的隐层神经元而言的，通过对隐层神经元的大部分输出进行抑制使网络达到一个稀疏的效果。

由于自编码器最初提出是基于降维的思想，但是当隐层节点比输入节点多时，自编码器就会失去自动学习样本特征的能力，高维而稀疏的表达固然是好，但此时就需要对隐层节点进行一定的约束，因此提出对隐层节点进行一些稀疏性的限值。

Ranzato M. 等^[30, 31]探讨了各种形式的稀疏性，并提出了稀疏惩罚项和 $\log Z$ 项之间的联系。Glorot X.^[32]等提出了一种在稀疏自编码器的输出中实现了真正为零的方式。

3.3.3 去噪自编码器

去噪自编码器 (Denoising Auto-Encoder, DAE)^[33] 是一类接受损坏数据作为输入，并训练来预测原始未被损坏数据作为输出的自编码器。它是自编码算法的一个变种，其实就是在自编码算法上加入了噪声鲁棒性约束。

去噪自编码器的过程是：先将原始输入数据进行随机添加噪声干扰，得到受干扰的输入数据。自编码器通过编码函数将其映射到隐藏层，得到隐藏层特征表达式，接着自编码器通过解码函数，将隐藏层的特征表达式再映射回到输出层，完成输入数据重构。若重构数据能很好地保持原始输入数据的信息，那么就说明该去噪自编码器具有很好的鲁棒性。

3.3.4 收缩自编码器

收缩自编码器 (Contractive Auto-Encoder, CAE)，是 Rifai S. 等^[31]提出的一种正则自编码器。它在编码 $h=f(x)$ 的基础上添加了显示的正则项，鼓励 f 的导数尽可能小，它的惩罚项 $\Omega(h)$ 是平方 Frobenius 范数，作用于与编码器的函数相关偏导数的 Jacobian 矩阵。

去噪自编码器与收缩自编码器存在一定的联系。它们在小高斯噪声的限制下，去噪重构误差与收缩惩罚项是等价的。即去噪自编码器能抵抗小且有限的输入扰动，而收缩编码器使特征提取函数能抵抗极小的输入扰动^[34]。

3.3.5 自编码器的应用

自编码器在现实生活中被应用到多个领域。在图像处理方面被用来进行手写体数字识

别^[35]、遥感图像分类^[36]、高光谱的图像分类和变化检测^[13, 37]等,在语音识别方面被用来进行噪声鲁棒性研究^[38]和语音情感识别^[39]等,在故障检测方面被用来进行变压器故障检测^[40]和风电机组齿轮箱故障检测^[41]等。

3.4 深度循环和递归神经网络

3.4.1 深度循环神经网络

循环神经网络 (Recurrent Neural Network) 是由 Rumelhart D. 等^[28]提出的一类专门用来处理序列的神经网络,它可以像神经网络那样扩展到更长的序列。

循环神经网络层级结构相比于 CNN 来说比较简单,它主要由输入层、隐藏层和输出层组成。其中隐藏层之间的节点不再是无连接的,而是有连接的,并且隐藏层的输入不仅包括输入层的输出还包括上一时刻隐藏层的输出。这就使得一个序列当前的输出与前面的输出也有关,从而实现了时间记忆的功能。

循环神经网络通过使用有自反馈的神经元,能够处理任意长度的序列。相比传统的深度前馈网络,它更加符合生物神经元的连接方式。并且循环神经网络已经被广泛地应用在自然语言处理等领域,取得了许多成果。

3.4.2 深度递归神经网络

递归神经网络 (Recursive Neural Network) 由 Pollack J.^[42]引入, Bottou L.^[43]描述了这类网络的潜在用途——学习推论。递归神经网络的结构与循环神经网络的链式结构不同,采用的是树状阶层结构,且网络节点按其连接顺序对输入信息进行递归。递归神经网络与其他模型的隐层之间彼此独立、逐层提取特征不同的是,它能对上层的信息进行记忆,并添加到本层的计算输出中。因此保证了数据间一定的关联性。递归神经网络通常用于描述动态时间行为序列,使状态数据在网络中循环传递。其优势在于处理语音文本信息。

而深度递归神经网络的一个明显的优势是:对于长度为 τ 的序列,深度 (通过非线性操作的组合数量来衡量) 可以急剧地从 τ 下降至 $O[\log(\tau)]$,这可能有助于解决长期依赖问题。

3.4.3 深度循环和递归神经网络的应用

深度循环和递归神经网络在自然语言处理领域取得了极大的成功,被用于语言模型与文本生成、机器翻译、语音识别和图像描述生成等方面。例如,微软在 2016 年使用循环神经网络语言模型 (Recurrent Neural Network based Language Modeling, RNN-LM) 将 switchboard 的词识别错误率降低到了 6.3%。

4 深度学习的发展趋势

4.1 技术方面发展趋势

根据深度学习的特点,在技术方面的将会呈现以下几点发展趋势。

一是深度神经网络呈层数越来越多,结构越来越复杂的趋势。由于深度学习具有只要增加层数就可以达到得到足够的特征的目的,因此一般来说,网络层数越多,结构越复杂深度学习的性能越好,学习效果也越来越好。

二是深度神经网络节点功能不断丰富。业界探索并提出了新型神经网络节点,使得神经网络的功能越来越丰富。节点越来越丰富,不断接近人脑的结构,将更加有利于克服目前神经网络存在的局限性。

三是深度学习与多种机器学习技术不断融合发展。深度学习可以与强化学习、迁移学习等不同的机器学习技术融合,以解决单项技术面临的一些缺陷。

4.2 应用领域方面发展趋势

在领域方面,深度学习具有较好的迁移学习的性质,一个模型训练好后拿到另一个问题上做简单的改进就可以继续使用。由于深度学习在计算机视觉和语音识别方优于过传统方法,其中一些好的方法经过改进,也适用于其他领域。例如深度学习在处理海量数据时在并行处理、进行模式识别特征提取、数据预测等方面都有巨大的优势,这与声学研究具有极大的契合性,因此可以在声学处理上运用深度学习解决部分问题。

5 结 语

尽管深度学习在计算机视觉和语音识别领域得到了广泛运用,但在地球物理领域里还处于起步阶段,主要用于断层、岩性、盐丘的识别研究,地电场异常检测,天然气储层预测等方面,卷积神经网络和深度神经网络为常用的研究方法。但深度学习在声学研究方面的应用还极为有限。由于深度学习在检测和识别的能力与声学研究契合度高,使得深度学习在声学研究上的潜力十分巨大。

参 考 文 献

- [1] GOODFELLOW I, BENGIO Y, COURVILLE A. Deep Learning [M]. Cambridge: MIT Press, 2016.
 - [2] HINTON G E, SALAKHUTDINOV R R. Reducing the Dimensionality of Data with Neural Networks [J]. Science, 2006, 313 (5786): 504-507.
 - [3] Hinton G E. Rectified Linear Units Improve Restricted Boltzmann Machines Vinod Nair [C] // 27th International Conference on Machine Learning. Madison: Omnipress, 2010.
 - [4] KRIZHEVSKY A, SUTSKEVER I, HINTON G. ImageNet Classification with Deep Convolutional Neural Networks [C] //Advances in Neural Information Processing Systems. Cambridge: MIT Press, 2012.
 - [5] SILVER D, HUANG A, MADDISON C J, et al. Mastering the game of Go with deep neural networks and tree search [J]. Nature, 2016, 529 (7587): 484-489.
 - [6] WAIBEL A, HANAZAWA T, HINTON G E, et al. Phoneme recognition using time-delay neural networks [J]. IEEE Transactions on Acoustics Speech and Signal Processing, 1989, 37 (3): 328-339.
 - [7] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86 (11): 2278-2324.
 - [8] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-Scale Image Recognition [J]. Computer Science, 2014.
 - [9] SZEGEDY C, LIU W, JIA Y, et al. Going Deeper with Convolutions [C] // 2015 IEEE Conference
- 250 —

on Computer Vision and Pattern Recognition (CVPR) . IEEE, 2015.

- [10] GIRSHICK R, DONAHUE J, DARRELLAND T, et al. Rich feature hierarchies for object detection and semantic segmentation [C] // 2014 IEEE Conference on Computer Vision and Pattern Recognition: IEEE, 2014.
- [11] GIRSHICK R. Fast R-CNN [J] . Computer Science, 2015.
- [12] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks [J] . Computer Science, 2015.
- [13] 焦李成. 深度学习、优化与识别 [M] . 北京: 清华大学出版社, 2017.
- [14] 韩卫雪, 周亚同, 池越. 基于深度学习卷积神经网络的地震数据随机噪声去除 [J] . 石油物探, 2018, 57 (6): 862-869, 877.
- [15] POULTON M M, STERNBERG B K, GLASS C E. Location of subsurface targets in geophysical data using neural networks [J] . GEOPHYSICS, 1992, 57 (12): 1534-1544.
- [16] KOONS H C, GORNEY D J. A neural network model of the relativistic electron flux at geosynchronous orbit [J] . Journal of Geophysical Research, 1991, 96 (A4): 5549-5556.
- [17] HINTON G E, OSINDERO S, TEH Y W. A Fast Learning Algorithm for Deep Belief Nets [J] . Neural Computation, 2006, 18 (7): 1527-1554.
- [18] DESJARDINS G, BENGIO Y. Empirical Evaluation of Convolutional RBMs for Vision [J] . 2008.
- [19] 陆军建, 林家骏. 基于 CUDA 和深度置信网络的手写字符识别 [J] . 华东理工大学学报 (自然科学版), 2015, 41 (2): 210-215.
- [20] MLECZKO W K, KAPUŚCINSKI T, NOWICKI R K. Rough Deep Belief Network - Application to Incomplete Handwritten Digits Pattern Classification [C] // International Conference on Information and Software Technologies. Berlin: Springer International Publishing, 2015: 400-411.
- [21] 张董, 游福成, 王惠华, 等. 受限制 Boltzmann 机深度置信网络与手写数字识别 [J] . 北京印刷学院学报, 2016, 24 (4): 56-58.
- [22] LI C, WEI W, WANG J, et al. Face Recognition Based on Deep Belief Network Combined with Center-Symmetric Local Binary Pattern [M] //Advanced Multimedia and Ubiquitous Engineering. Springer Singapore, 2016.
- [23] 柴瑞敏, 曹振基. 基于改进的稀疏深度信念网络的人脸识别方法 [J] . 计算机应用研究, 2015, 32 (7): 2179-2183.
- [24] LIU P, HAN S, MENG Z, et al. Facial Expression Recognition via a Boosted Deep Belief Network [C] // 2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR) . IEEE Computer Society, 2014.
- [25] LIN L, DONG H, SONG X. DBN-based Classification of Spatial-spectral Hyperspectral Data [M] // Advances in Intelligent Information Hiding and Multimedia Signal Processing. Springer International Publishing, 2017: 53-60.
- [26] 高鑫, 欧阳宁, 袁华. 基于快速去噪和深度信念网络的高光谱图像分类方法 [J] . 桂林电子科技大学学报, 2016 (6): 469-476.
- [27] ZHAO Q, MA J, GONG M, et al. Three-Class Change Detection in Synthetic Aperture Radar Images Based on Deep Belief Network [J] . Bio-Inspired Computing-Theories and Applications, 2016, 13 (6): 3757-3762.
- [28] RUMELHART D E. Learning Representations by Back-Propagating Errors [J] . Nature, 1986, 323: 533-536.
- [29] SCHÖLKOPF B, PLATT J, HOFMANN T. Greedy layer-wise training of deep networks [J] . Ad-

vances in Neural Information Processing Systems, 2007: 153-160.

- [30] RANZATO M, POULTNEY C, CHOPRA S, et al. Efficient Learning of Sparse Representations with an Energy-Based Model [C] // Advances in Neural Information Processing Systems (NIPS 2006) . 2006: 1137-1144.
- [31] RANZATO Y M. Sparse feature learning for deep belief networks [C] // International Conference on Neural Information Processing Systems. 2007.
- [32] GLOROT X, BORDES A, BENGIO Y. Domain Adaptation for Large-Scale Sentiment Classification: A Deep Learning Approach [C] // International Conference on International Conference on Machine Learning. Madison: Omnipress, 2011.
- [33] VINCENT P, LAROCHELLE H, BENGIO Y, et al. Extracting and Composing Robust Features with Denoising Autoencoders [C] //International Conference on Machine Learning. ACM, 2008: 231.
- [34] ALAIN G, BENGIO Y. What Regularized Auto-Encoders Learn from the Data Generating Distribution [J] . Journal of Machine Learning Research, 2014, 15: 3563-3593.
- [35] 余涛. 基于稀疏自编码器的手写体数字识别 [J] . 数字技术与应用, 2017 (1): 66, 68.
- [36] 张一飞, 陈忠, 张峰, 等. 基于栈式去噪自编码器的遥感图像分类 [J] . 计算机应用, 2016 (S2): 171-174, 188.
- [37] 戴晓爱, 郭宋恒, 任消, 等. 基于堆栈式稀疏自编码器的高光谱影像分类 [J] . 电子科技大学学报, 2016, 45 (3): 382-386.
- [38] 黄丽霞, 王亚楠, 张雪英, 等. 基于深度自编码网络语音识别噪声鲁棒性研究 [J] . 计算机工程与应用, 2017 (13): 49-54.
- [39] 朱芳枚, 赵力, 梁瑞宇, 等. 面向中文语音情感识别的改进栈式自编码结构 [J] . 东南大学学报 (自然科学版), 2017 (4): 631-636.
- [40] 许倩文, 吉兴全, 张玉振, 等. 基于栈式稀疏自编码器的矿用变压器故障诊断 [J] . 工矿自动化, 2018, 44 (10): 33-37.
- [41] 刘辉海, 赵星宇, 赵洪山, 等. 基于深度自编码网络模型的风电机组齿轮箱故障检测 [J] . 电工技术学报, 2017 (17) .
- [42] POLLACK J B. Recursive distributed representations [J] . Artificial Intelligence, 1990, 46 (1-2): 77-105.
- [43] BOTTOU, L. From machine learning to machine reasoning [J] . Machine Learning, 2014, 94 (2): 133-149.